《基于大语言模型的自主智能体研究综述》导读

A survey on large language model based autonomous agents.

作者：Wang, L., Ma, C., Feng, X. *et al.*

出处：Frontiers of Computer Science 18, 186345 (2024)

https://doi.org/10.1007/s11704-024-40231-1

使用的大模型：deepseek

引言

自主智能体作为实现人工通用智能的核心载体，长期以来是学术界与工业界的研究焦点。传统的智能体构建方法多依赖于强化学习，在封闭或受限的环境中进行策略训练。这类方法通常需要大量人工交互数据进行特定任务的拟合，不仅训练成本高昂，且所获得的智能体在应对开放域、非结构化环境时，往往缺乏人类特有的常识推理与泛化能力。

研究背景

近年来，大语言模型的发展为突破上述瓶颈带来了曙光。LLMs 通过在海量网络语料上进行预训练，具备了丰富的世界知识与强大的语言理解能力。研究者们开始探索如何将 LLMs 从单纯的文本生成工具，升级为能够自主感知、规划与行动的智能体。然而，该领域发展迅猛且文献庞杂，缺乏系统的梳理。本文正是在这一背景下应运而生，旨在对 LLM-based 智能体的构建、应用与评估进行全面综述，为后续研究建立清晰的知识地图。

研究方法

本文的核心贡献在于提出了一个统一的概念框架，将 LLM-based 智能体的内部架构抽象为四个关键模块，系统地揭示了其工作原理。

1、画像模块：该模块定义了智能体的“身份”，如职业、性格及社会关系。其构建方式包括手工定义、基于 LLM 的生成以及真实数据集对齐。画像信息被注入提示词中，从根本上决定了智能体的行为风格与决策偏好。

2、记忆模块：该模块模拟了人类的记忆机制。它不仅包含用于处理当前上下文的工作记忆，还引入了利用向量数据库实现的长期记忆，支持信息的存储、检索与反思。通过记忆模块，智能体能够积累经验，实现自我进化。

3、规划模块：面对复杂任务，智能体需具备拆解与推理能力。规划模块涵盖无反馈的路径推理和多路径探索，以及基于环境、人类或模型反馈的动态调整机制，使智能体能够处理需要长时推理的复杂挑战。

4、动作模块：作为智能体的“输出端”，该模块不仅依赖 LLM 自身的内部知识（如对话、常识），更关键的是能调用外部工具，如 API、数据库或专家模型，从而突破语言模型的固有限制，真正实现对现实世界的影响。

此外，论文将智能体的能力获取分为两类：一是通过微调将领域知识注入模型；

二是通过提示工程与机制工程在不更新参数的情况下激发模型潜能。

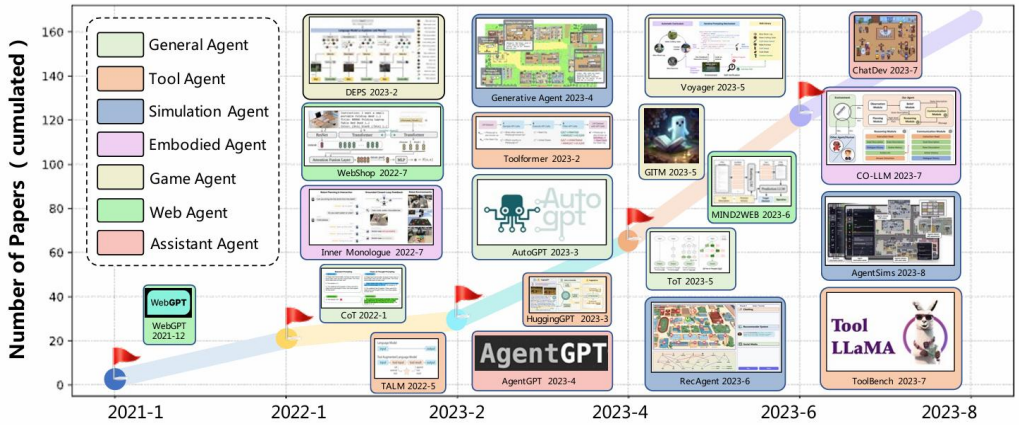

结果

论文对现有研究进行了大规模梳理，并展示了 LLM-based 智能体在三大领域的广泛应用前景。

1、社会科学领域：智能体被用于构建虚拟社会模拟器。通过赋予不同角色，研究者可以在可控环境中观察人类行为、观点传播及社会现象的涌现，为社会学、经济学和心理学研究提供了全新的实验范式。

2、自然科学领域：智能体可作为科学家的“实验助手”。例如在化学与材料科学中，智能体能够阅读文献、规划实验步骤、调用计算工具，甚至自主执行常规实验流程，极大地提升了科研效率。

3、工程领域：在软件工程中，多个智能体可协作完成从设计到测试的完整开发生命周期；在机器人领域，智能体则作为高层的任务规划器，将自然语言指令转化为具体的物理动作序列。

在评估方面，论文归纳了基于人类判断的主观评估与基于量化指标的客观评估两大类方法，并介绍了 AgentBench、WebShop 等主流基准测试平台。

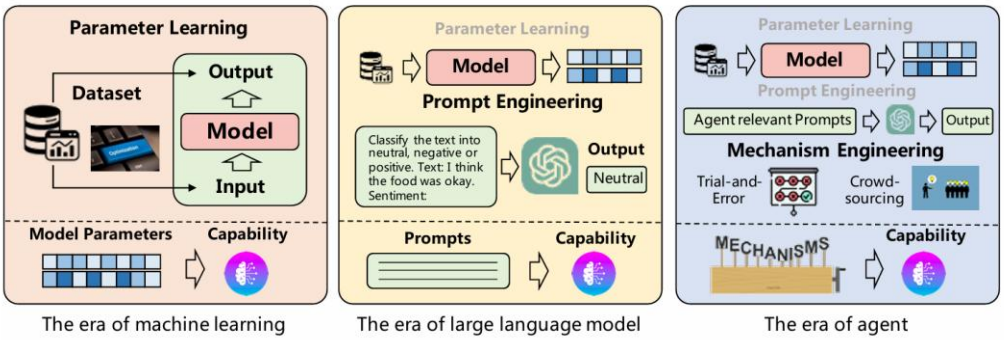

小结

本文作为 LLM-based 自主智能体领域的首篇系统性综述，具有极高的参考价值。其最大亮点在于构建了一个通用且简洁的架构框架，将碎片化的研究统一于“画像-记忆-规划-动作”的逻辑闭环中，帮助读者快速建立起对该领域的整体认知。

从批判性视角来看，尽管研究前景广阔，但该领域仍处于早期探索阶段。首先，鲁棒性不足：当前的智能体高度依赖复杂的提示词工程，输入微调可能导致行为剧变，稳定性堪忧。其次，评估标准缺失：现有评估多集中于任务完成率，而对于智能体的社会性、伦理性及长期行为的评估尚不完善。最后，安全对齐困境：当智能体被用于社会模拟时，若过度对齐正面价值观，反而会丧失模拟真实复杂社会的能力。如何在开放性与安全性之间取得平衡，将是未来研究的核心挑战。总体而言，这篇综述不仅总结了过去的成就，更为我们指明了前行的方向。